Αναζήτηση Απομακρυσμένων Ομολόγων Πρωτεϊνών με Προσεγγιστικές Μεθόδους ANN και ESM-2 Embeddings

Τσεκρέκος Έγκορ-Ανδριανός, Δημακόπουλος Θεόδωρος

14 Ιανουαρίου 2026

Περίληψη

Η παρούσα αναφορά παρουσιάζει τα αποτελέσματα της αξιολόγησης πέντε μεθόδων Προσεγγιστικής Αναζήτησης Πλησιέστερου Γείτονα (Approximate Nearest Neighbor - ANN) για την εύρεση ομοιότητας πρωτεϊνών, αξιοποιώντας τις διανυσματικές αναπαραστάσεις του γλωσσικού μοντέλου ESM-2. Οι μέθοδοι συγκρίνονται με τον αλγόριθμο BLAST ως σημείο αναφοράς (reference), χρησιμοποιώντας ένα σύνολο 10 αντιπροσωπευτικών ανθρώπινων πρωτεϊνών ως ερωτήματα σε μια βάση δεδομένων που περιλαμβάνει 573,661 πρωτεΐνες από το Swiss-Prot. Στόχος είναι η ανάδειξη της ικανότητας των embeddings να εντοπίζουν απομακρυσμένες ομόλογες πρωτεΐνες (remote homologs) που διαφεύγουν της παραδοσιακής στοίχισης αλληλουχιών.

1 Εισαγωγή

Η ανάλυση πρωτεϊνικών αλληλουχιών αποτελεί θεμέλιο λίθο της υπολογιστικής βιολογίας. Ενώ παραδοσιακά εργαλεία όπως το BLAST βασίζονται στην ομοιότητα αλληλουχίας, η χρήση νευρωνικών δικτύων (όπως το ESM-2) επιτρέπει την παραγωγή διανυσμάτων (embeddings) που κωδικοποιούν δομικές και λειτουργικές πληροφορίες. Η εργασία αυτή εστιάζει στην εφαρμογή και αξιολόγηση αλγορίθμων ANN (LSH, Hypercube, IVF, Neural LSH) για την αποδοτική αναζήτηση σε αυτόν τον διανυσματικό χώρο, εξετάζοντας την αντισταθμιστική σχέση μεταξύ ταχύτητας και ακρίβειας, καθώς και τη βιολογική εγκυρότητα των αποτελεσμάτων.

2 Μεθοδολογία και Τεχνικές Λεπτομέρειες

Για την υλοποίηση της πειραματικής διαδικασίας χρησιμοποιήθηκε η βάση δεδομένων Swiss-Prot, η οποία περιέχει 573,661 πρωτεΐνες. Η παραγωγή των embeddings πραγματοποιήθηκε με το μοντέλο `facebook/esm2_t6_8M_UR50D`, το οποίο παράγει διανύσματα 320 διαστάσεων. Ως μέτρο αξιολόγησης χρησιμοποιήθηκε η μετρική Recall@50 συγκριτικά με τα 50 κορυφαία αποτελέσματα του BLAST. Η εκτέλεση των πειραμάτων έλαβε χώρα αποκλειστικά σε περιβάλλον CPU.

Οι αλγόριθμοι παραμετροποιήθηκαν ως εξής για να επιτευχθεί η βέλτιστη ισορροπία απόδοσης: Ο αλγόριθμος **Euclidean LSH** ρυθμίστηκε με $k = 6$ συναρτήσεις κατακερματισμού, $L = 8$ πίνακες και πλάτος bucket $w = 1.0$. Για τον **Hypercube**, χρησιμοποιήθηκαν $d = 12$ διαστάσεις προβολής, $w = 1.5$, με όριο υποψηφίων $M = 5000$ και 2 probes. Οι μέθοδοι **IVF-Flat** και **IVF-PQ** χρησιμοποίησαν nlist=1000 συστάδες και nprobe=50, με τον IVF-PQ να εφαρμόζει κβαντισμό με $M = 16$ subquantizers των 8 bits. Τέλος, ο **Neural LSH** εκπαιδεύτηκε για 15 εποχές με κρυφά επίπεδα μεγέθους 128, δημιουργώντας 400 διαμερίσεις και αναζητώντας σε $T = 50$ υποψήφια buckets.

3 Ποσοτική Σύγκριση Μεθόδων

Η ανάλυση των αποτελεσμάτων ανέδειξε σημαντικές διαφοροποιήσεις στην απόδοση των αλγορίθμων. Όπως φαίνεται στον Πίνακα 1, ο αλγόριθμος Neural LSH αναδεικνύεται ως η ταχύτερη μέθοδος, επιτυγχάνοντας 9.5 ερωτήματα ανά δευτερόλεπτο (QPS), επίδοση που είναι 23.75 φορές υψηλότερη από τον Euclidean LSH και περίπου 4 φορές ταχύτερη από το ίδιο το BLAST. Αντιθέτως, οι μέθοδοι IVF (Flat και PQ) παρουσίασαν εξαιρετικά χαμηλή ταχύτητα (κοντά στο 0.0 QPS) λόγω του υψηλού κόστους της συσταδοποίησης k-means σε CPU.

Όσον αφορά την ακρίβεια, οι μέθοδοι IVF-Flat, IVF-PQ και Neural LSH σημείωσαν την υψηλότερη επίδοση με μέσο Recall@50 της τάξης του 0.67. Ο αλγόριθμος Hypercube προσέφερε μια ικανοποιητική μέση λύση (Recall 0.60), ενώ ο Euclidean LSH υστερούσε σημαντικά (0.38).

Πίνακας 1: Συνολικά αποτελέσματα (Μέσος όρος 10 ερωτημάτων, N=50)

Μέθοδος	**Χρόνος (ς)**	**QPS**	**Recall@50**
Euclidean LSH	36.58	0.4	0.38
Hypercube	18.61	1.1	0.60
IVF-Flat	1594.09	0.0	0.67
IVF-PQ	3831.64	0.0	0.67
Neural LSH	10.07	**9.5**	0.67
BLAST (Ref)	4.41	2.3	1.00

Η ανάλυση ανά πρωτεΐνη-στόχο (Πίνακας 2) δείχνει ότι η απόδοση των μεθόδων εξαρτάται έντονα από το είδος της πρωτεΐνης. Για παράδειγμα, στην οικογένεια της αιμοσφαιρίνης (HBB, HBA) και σε πρωτεΐνες όπως η Calmodulin και η KRAS, οι μέθοδοι ANN επιτυγχάνουν πολύ υψηλά ποσοστά ανάκλησης (0.88 - 0.90), υποδεικνύοντας ότι ο χώρος των embeddings αποτυπώνει πιστά τις συγκεκριμένες οικογένειες. Αντίθετα, σε πρωτεΐνες όπως η Ινσουλίνη (Insulin), η ανάκληση είναι χαμηλότερη, γεγονός που πιθανώς οφείλεται στο μικρό μέγεθος της πρωτεΐνης και τη δυσκολία διάκρισης στο χώρο των embeddings.

Πίνακας 2: Ανάλυση Recall@50 ανά Πρωτεΐνη-Ερώτημα

ID	**Πρωτεΐνη**	**LSH**	**Hypercube**	**IVF-Flat**	**IVF-PQ**	**Neural**
P00533	EGFR (Human)	0.11	0.55	0.59	0.59	0.59
P04637	p53 (Human)	0.25	0.61	0.64	0.64	0.64
P00915	CAH1 (Human)	0.16	0.32	0.44	0.44	0.44
P68871	HBB (Human)	0.80	**0.90**	0.90	0.90	0.90
P62158	Calmodulin	**0.88**	**0.88**	0.88	0.88	0.88
P01308	Insulin (Human)	0.12	0.22	0.46	0.46	0.46
P00918	CAH2 (Human)	0.02	0.24	0.44	0.44	0.46
P69905	HBA (Human)	0.62	0.72	0.72	0.72	0.72
P01116	KRAS (Human)	0.40	**0.90**	0.90	0.90	0.90
P02144	Myoglobin	0.44	0.70	0.70	0.70	0.70

4 Βιολογική Αξιολόγηση και Remote Homologs

Ως απομακρυσμένη ομόλογη (remote homolog) ορίζεται μια πρωτεΐνη που εντοπίζεται σε μικρή Ευκλείδεια απόσταση στον χώρο των embeddings (τυπικά $L2 < 1.5$), αλλά δεν εμφανίζεται στα

50 κορυφαία αποτελέσματα του BLAST, παρουσιάζοντας συνήθως χαμηλή ομοιότητα αλληλουχίας ($< 30\%$) παρά τη διατήρηση παρόμοιας τρισδιάστατης δομής ή λειτουργίας. Η ανάλυση των αποτελεσμάτων ανέδειξε αρκετές τέτοιες περιπτώσεις, επιβεβαιώνοντας την αξία των ESM-2 embeddings.

4.1 Ανάλυση Συγκεκριμένων Περιπτώσεων

Στην περίπτωση της πρωτεΐνης **EGFR (P00533)**, μιας τυροσινικής κινάσης υποδοχέα, εντοπίστηκαν πέντε πιθανές απομακρυσμένες ομόλογες. Χαρακτηριστικό παράδειγμα αποτελεί η πρωτεΐνη Q5CD18 (Tyrosine kinase Fer), η οποία αν και δεν εμφανίζεται στα αποτελέσματα του BLAST, διαθέτει παρόμοια περιοχή κινάσης (Pkinase_Tyr) και εντοπίστηκε σε απόσταση 1.21. Ωστόσο, παρατηρήθηκαν και περιπτώσεις όπως η O43291 (SPEN), η οποία παρότι βρίσκεται κοντά ($L2 = 1.67$), λειτουργεί ως μεταγραφικός καταστολέας, υποδεικνύοντας ότι η ομοιότητα στα embeddings μπορεί να οφείλεται σε κοινά μοτίβα αλληλεπίδρασης και όχι απαραίτητα σε κοινή ενζυμική λειτουργία.

Εξαιρετικό ενδιαφέρον παρουσιάζει η οικογένεια της **Καρβονικής Ανυδράσης (CAH)**. Για την πρωτεΐνη CAH2 (P00918), τα embeddings εντόπισαν επιτυχώς προκαρυωτικές μορφές του ενζύμου (π.χ. P75073), οι οποίες έχουν πολύ χαμηλή ομοιότητα αλληλουχίας με τις ανθρώπινες μορφές αλλά ανήκουν στην ίδια υπερ-οικογένεια. Επιπλέον, η ανάλυση των παραλόγων μεταξύ CAH1 και CAH2 έδειξε ότι τα embeddings διατηρούν τη φυλογενετική δομή, τοποθετώντας τις γνωστές ισομορφές (CA III, CA IV, CA VI) σε κοντινές αποστάσεις.

Για την πρωτεΐνη **Ινσουλίνη (P01308)**, εντοπίστηκε η πρωτεΐνη Q6GZX4 με μηδενική απόσταση, η οποία δεν βρέθηκε από το BLAST, υποδηλώνοντας την ύπαρξη μιας πανομοιότυπης μορφής embedding (πιθανώς ένα θραύσμα ή πεπτίδιο ινσουλίνης). Παρ΄ όλα αυτά, η μικρή αλληλουχία της ινσουλίνης οδήγησε και σε ψευδώς θετικά αποτελέσματα σε μεγαλύτερες αποστάσεις ($L2 > 2.5$), χωρίς προφανή βιολογική σύνδεση.

Τέλος, στην οικογένεια της **Αιμοσφαιρίνης (HBB)**, παρατηρήθηκε σχεδόν απόλυτη ταύτιση μεταξύ της απόστασης embedding και της βιολογικής συγγένειας, με τις πρωτεΐνες χιμπαντζή και γορίλα να εμφανίζονται ως οι πλησιέστεροι γείτονες, επιβεβαιώνοντας την ποιότητα του μοντέλου ESM-2 για καλά διατηρημένες οικογένειες.

4.2 Περιορισμοί και Ψευδώς Θετικά Αποτελέσματα

Η μελέτη ανέδειξε ορισμένους περιορισμούς της προσέγγισης. Παρατηρήθηκε ότι γείτονες με Ευκλείδεια απόσταση μεγαλύτερη του 1.5 είναι συχνά ψευδώς θετικοί (false positives), χωρίς άμεση βιολογική συσχέτιση. Επιπρόσθετα, τα embeddings φαίνεται να είναι λιγότερο διακριτικά για μικρές πρωτεΐνες (50-100 αμινοξέων), ενώ σε ορισμένες περιπτώσεις μπορεί να προκύψει σύγχυση λόγω σύστασης αμινοξέων ή παρουσίας κοινών domains σε πρωτεΐνες με διαφορετική συνολική λειτουργία.

5 Συμπεράσματα

Η συγκριτική αξιολόγηση των μεθόδων ANN ανέδειξε τον αλγόριθμο **Neural LSH** ως τη βέλτιστη επιλογή για παραγωγική χρήση, καθώς προσφέρει τον καλύτερο συνδυασμό υψηλής ταχύτητας (9.5 QPS) και ακρίβειας (Recall 0.67), υπερέχοντας σημαντικά του BLAST σε χρόνο εκτέλεσης. Οι μέθοδοι IVF, αν και ακριβείς, περιορίζονται από το υπολογιστικό κόστος της συσταδοποίησης σε περιβάλλον χωρίς GPU.

Από βιολογικής σκοπιάς, τα ESM-2 embeddings αποδείχθηκαν ισχυρό εργαλείο για τον εντοπισμό απομακρυσμένων ομολόγων, αποκαλύπτοντας λειτουργικές συσχετίσεις που διαφεύγουν της ανάλυσης αλληλουχίας. Ωστόσο, η χρήση τους απαιτεί προσεκτική επιλογή ορίων απόστασης και, ιδανικά, συνδυασμό με δομική επαλήθευση για την ελαχιστοποίηση των ψευδώς θετικών αποτελεσμάτων.